

Report

Ich würde die Streuung bei Namen anhand der Häufigkeit und Anzahl der unterschiedlichen Vor- und Nachnamen berechnen. In der Realität kommen Namen unterschiedlich häufig vor, sie sind also nicht gleichmäßig verteilt. Sollte die Faker-Bibliothek saubere zufällige Datensätze liefern (was unrealistisch wäre), müssten alle Vornamen bzw. alle Nachnamen annähernd gleich oft vorkommen.

Die hohe Zufälligkeit der Streuung der erzeugten Namen würde sich anhand einer hohen Anzahl unterschiedlicher Namen zeigen, die allerdings alle ähnlich häufig vorkommen. Das wäre realitätsfern.

Ich habe die Streuung der Bibliothek überprüft, indem ich folgende Daten ausgelesen habe:

Verteilung der Vornamen

- Anzahl unterschiedlicher Vornamen: 2002
- Häufigster Vorname: Jonas (492)
- Seltenster Vorname: Natalja (199)
- Durchschnittliche Häufigkeit: 249,75

Verteilung der Nachnamen

- Anzahl unterschiedlicher Nachnamen: 404
- Häufigster Nachname: Seifert (2533)
- Seltenster Nachname: Tintzmann (1123)
- Durchschnittliche Häufigkeit: 1237,62

Der häufigste Vorname kommt 2,47-mal so oft vor wie der seltenste. Der häufigste Nachname kommt 2,26-mal so oft vor wie der seltenste. Dies entspricht einer realistisch ungleichmäßigen Verteilung und ist somit realitätsnah.

Performance der Datenabfrage

Zur Überprüfung der Performance wurde folgender SQL-Select verwendet:

```
SELECT COUNT(DISTINCT vorname) FROM personen;
```

Ohne Index

- Run Time: real 0.305, user 0.281250, sys 0.031250
- Seitengröße: 4096B
- Seitenanzahl: 2870
- Speicherbedarf: 11,755520 MB

Mit Index

- Run Time: real 0.057, user 0.062500, sys 0.000000
- Seitengröße: 4096B
- Seitenanzahl: 6703
- Speicherbedarf: 27,455488 MB

Die Abfrage ist mit Index etwa fünfmal schneller, benötigt jedoch 2,34-mal mehr Speicher.

Vergleich mit biased Datenbank (50% Vorname „Max“)

Ohne Index

- Run Time: real 0.200, user 0.156250, sys 0.031250
- Seitengröße: 4096B
- Seitenanzahl: 2648
- Speicherbedarf: 10,846208 MB

Mit Index

- Run Time: real 0.064, user 0.046875, sys 0.000000
- Seitengröße: 4096B
- Seitenanzahl: 4336
- Speicherbedarf: 17,760256 MB

Die Performance ist etwa dreimal besser, der Speicherbedarf steigt um den Faktor 1,64.

Auffällig ist, dass der Select bei der indexierten biased Datenbank weniger Speicher benötigt und fast die gleiche Performance bietet wie die indexierte normale Datenbank. Dies liegt vermutlich daran, dass der Schlüsselwert „Vorname“ in 50% der Fälle identisch ist und somit weniger Knoten im Index erzeugt werden müssen.